

Programmation Statistique sous R

EXAMEN

Documents autorisés

Mathieu GAULTIER et Anthony SARDELLITTI

AVRIL 2024

CONSIGNES

Vous avez 1h30 pour réaliser l'ensemble du devoir. Vous devez vous connecter sur les sessions EXAM. Document papier autorisé, document numérique à uploader sur votre session EXAM via une clé USB **avant le début de l'examen**.

Pour que votre travail soit pris en compte et pour ne pas avoir de pénalités :

- Le script R est à rendre sur la session EXAM
- Votre fichier doit se nommer **NOM_PRENOM** et doit être un script R
- Le rendu est individuel
- Pour chaque question n'oubliez pas :
 - d'écrire le code R permettant de répondre à la question
 - de préciser le numéro de la question et de l'exercice en commentaire.

Exemple de réponse :

```
# Exercice A-1  
Data<-read.csv()
```

En cas de non respect des consignes, des pénalités peuvent être appliquées.

Présentation

Pour cet examen, on utilise les fichiers `TheOffice.csv` et `TheOfficeDialogue.csv`. The Office est une série télévisée américaine de sitcom qui dépeint la vie quotidienne des employés de bureau de la fictive Dunder Mifflin Paper Company. Le dataset du fichier `TheOffice.csv` présente les statistiques de chaque épisode. Le dataset `TheOfficeDialogue.csv` correspond à toutes les répliques de la série. Il n'y a pas de spoil dans cet examen.

Recommandations

- Copier les datasets sur votre bureau
- Ne pas ouvrir le fichier avec excel mais privilégier le bloc note ou Notepad+
- S'autocorriger et vérifier ses résultats avant de se lancer dans la question suivante
- Sauvegarder votre script régulièrement et **avant de le déposer sur le serveur**
- Effectuer plusieurs étapes pour les questions complexes.
- Ouvrir les ressources HTML avec EDGE et non CHROME

Exercice 1 : Importer les données

1. A l'aide de la fonction `read.csv()`, importer le jeu de données `TheOffice.csv` dans un objet appelé `dfEpisode` puis le jeu de données `TheOfficeDialogue.csv` dans un objet appelé `dfDialogue`.
2. Prendre connaissance des données en faisant un résumé puis convertir les variables qualitatives comme `Season`, `Episode_Number` et `Character` en type `factor`.

Exercice 2 : Statistiques descriptives

Il est demandé de rédiger une phrase d'interprétation pour chaque graphique construit. N'oublier pas de mettre des titres et des noms d'axe pour chaque graphique

1. Représenter graphiquement les dix personnages avec le plus de dialogues
2. Quelle est la durée en heure de la série ?
3. Afficher les déciles de la distribution des notes (`Ratings`). Représenter ensuite cette distribution avec le graphique adapté et sa courbe densité. Que peut-on dire de cette courbe ?
4. Comparer graphiquement la distribution des notes par saison avec le graphique adapté. Quelle saison semble la mieux notée ? Vérifier cela en calculant la moyenne des notes de chaque saison avec la fonction adaptée puis les ajouter sur le graphique.
5. Représenter graphiquement le nombre de vues (`Viewership`) par saison de la plus vue à la moins vue. Quelles sont les 3 saisons avec le plus de vues ? Les valeurs sont en millions de vues.

Exercice 3 : Corrélation

1. Calculer puis commenter la corrélation entre les notes des épisodes et le nombre de vues. Représenter graphiquement cette relation.
2. Calculer puis commenter la corrélation entre les notes des épisodes et le nombre de personnage présents. Représenter graphiquement cette relation.

Exercice 4 : Une si bonne série ?

Un ami n'est pas très fan de cette série. Il affirme que si on prend 30 épisodes au hasard, la moyenne des notes ne dépasse pas 8/10. Vérifier avec une simulation d'échantillonnage si son affirmation est vraie.

1. Créer une fonction appelée `EchantillonEpisode()` qui prend en entrée le nombre d'épisode qu'on souhaite tiré au hasard parmi les notes des épisodes de la série. Voici un exemple du résultat attendu :

```
EchantillonEpisode(n=30)
```


```
## [1] 9.4 8.7 7.5 9.0 7.5 8.5 8.2 7.9 8.1 8.8 8.1 8.1 8.8 9.5 8.8 9.4 7.1 8.2 8.2  
## [20] 8.1 8.2 8.5 9.4 7.0 7.7 8.7 8.6 7.6 7.1 9.5
```

2. Répliquer cette expérience aléatoire 100 fois avec des échantillons de 30 épisodes au hasard et stockez les échantillons dans un dataframe. Voici un extrait des dix premières colonnes de ce qu'on pourrait avoir :

X1	X2	X3	X4	X5	X6	X7	X8	X9	X10
8.1	7.0	7.1	8.1	8.8	7.7	7.5	9.4	7.6	8.2
8.3	8.8	8.1	7.8	8.6	7.8	8.6	8.4	7.9	7.5
8.0	8.1	9.0	8.7	7.5	9.7	8.8	7.8	8.4	9.5
8.7	8.2	8.3	8.7	8.7	9.8	8.3	8.0	7.8	7.5
8.1	9.7	7.7	8.9	7.4	8.9	8.7	7.6	6.6	8.4
8.7	8.2	8.7	8.6	8.3	7.8	7.5	8.8	7.5	8.8
7.1	8.1	8.1	9.7	8.8	7.8	8.7	8.0	7.6	7.4
8.0	8.3	8.4	8.8	8.8	8.0	8.7	8.0	8.8	8.1
7.8	8.4	8.4	8.7	8.7	7.4	8.7	8.6	8.1	8.8
8.0	7.8	8.8	9.7	8.8	8.5	7.8	8.0	8.1	8.3
9.3	8.1	8.3	8.1	7.8	8.5	8.3	8.0	7.5	8.3
8.5	7.9	7.8	7.8	8.6	8.3	7.9	8.7	7.8	8.5
8.8	7.0	7.7	7.9	7.7	7.6	8.0	7.5	6.8	9.2
8.5	6.8	8.7	8.5	8.6	8.3	7.1	8.0	7.8	8.7
6.9	8.4	8.7	7.0	8.4	7.5	7.7	8.1	8.8	8.0
9.0	9.0	7.8	8.0	8.3	8.0	7.7	9.8	8.4	7.4
8.5	7.5	8.8	7.5	9.5	7.0	8.2	8.8	7.7	8.7
7.9	8.7	8.1	8.3	7.8	8.6	8.4	7.1	8.6	8.4
8.0	7.7	9.3	8.7	8.4	8.8	8.4	9.8	8.7	8.3
8.3	7.9	7.8	8.5	8.8	8.3	9.4	8.4	8.3	7.5
9.3	7.6	8.4	9.5	8.3	8.7	8.0	9.0	8.6	8.0
8.8	8.4	8.6	8.3	8.0	7.7	9.4	7.0	8.4	8.2
7.8	9.0	8.0	7.5	8.2	7.6	7.6	7.8	7.8	8.8
8.2	7.5	6.6	8.2	8.4	8.6	9.0	8.1	7.3	7.6
8.6	8.4	7.7	8.1	9.0	9.0	8.5	8.3	8.7	7.8
9.8	8.1	7.7	8.2	8.7	8.4	8.2	8.0	7.7	8.1
9.1	8.1	8.0	7.4	8.2	7.8	7.3	7.4	8.6	8.5
9.8	9.8	9.8	9.8	8.5	8.0	8.4	7.6	7.7	9.0
9.7	8.0	9.3	7.5	8.3	8.0	8.6	7.5	8.1	7.5
7.1	8.2	9.3	7.4	7.8	8.1	7.7	8.7	8.1	7.9

3. Calculer la moyenne de chaque échantillon avec la fonction adaptée et représenter toutes ces moyennes dans un histogramme. Voici un exemple du résultat attendu :

Distribution des moyennes des échantillons



4. Calculer une estimation par intervalle de confiance de la note moyenne de 30 épisodes avec un risque de se tromper de 5%. L'affirmation de notre ami est-elle vraie sachant que :

$$\bar{x} \pm z \times \frac{s}{\sqrt{n}}$$

Où :

- $\bar{x}$ est la moyenne de l'échantillon.
- s est l'écart type de l'échantillon.
- n est la taille de l'échantillon.
- z est le quantile de la loi normale.

L'intervalle de confiance à 95% pour la moyenne est [8.2 , 8.24]